

知の越境検索 システム構成図

Streamlit単一プロセスのPoC / 設計.md・仕様.md・実装計画.md 準拠 / 2026-09-30版 (実線=実装予定あり/破線=今回はスコープ外 [次フェーズで実装を検討]) ※5文書は9/30 MTG承認前の仮決定を含む

Streamlit Community Cloud (単一プロセス/Python)

app.py Streamlit アプリのエントリーポイント: 起動時にDB自動構築 → st.tabs() でタブ①②を切替

UI層 ui/ (Streamlit 1.64.0)

ui/tab_search.py
タブ① 検索窓・方式トグル
カードリスト (方向は need 固定)

ui/tab_techdb.py
タブ② 技術データベース
一覧・絞り込み・詳細

ui/cards.py
結果カード1件の描画
関連度%・要約・権利・実績

ui/detail.py
技術1件の詳細 (①②共用)
タブ①②から開く

検索ロジック search/ (Janome 0.5.0 / sentence-transformers 6.1.0 / numpy 1.26.4)

search/cross_search.py
BM25+ベクトル → RRFで統合
反対側10件+同じ側3件

search/bm25.py
FTS5 (4列) 上位50件

search/tokenizer.py
Janome分かち書き (索引側と共用)

search/vector.py
multilingual-e5-small
フィールド別の最大類似度 上位50件

search/rrf.py
RRF統合 (k=60)
候補10件を選定

後処理

① hit_judge.py
ヒットなし判定

② rephrase.py
言い換え候補 (今回はスコープ外)

③ scoring.py
関連度%へ変換

④ highlight.py
一致理由のハイライト

DB層 db/ + SQLite (FTS5+埋め込みBLOB。dbはGit管理外)

db/build_db.py
起動時に自動構築
schema+seeds投入 → FTS5索引
→ 全文書の埋め込みを計算
(ローカル無料)

knowledge.db (SQLite)
documents / embeddings / patents
projects / project_techs / project_products
search_logs + documents_fts (FTS5)

参照

INSERT

接続

db/repositories.py
CRUD・get_project_techs/get_claims

db/search_log.py
検索ログをINSERT (ヒット0件も記録)

db/connection.py
connect(): 全DBアクセスの共通窓口
接続ごとに foreign_keys=ON

開発者PC (開発時に手動で行う作業)

knowledge.db (編集先の本体)
手入力データを直接編集

ingest/summarize.py
「平たく言うと」要約を1回だけ生成

tools/export_seeds.py
コミット前に seeds.sql へ書き出し

GitHub リポジトリ (main)

アプリ本体・tests/
(配置は設計.md「構成」に従う)

db/schema.sql
テーブル定義

fixtures/seeds.sql
手入力データの正本 (テキスト)

クローラー (F-11/F-12)
ingest/crawler.py ほか・crawl.yml
今回はスコープ外 (次フェーズで実装を検討)

技術スタック

言語 Python
画面 Streamlit 1.64.0
DB SQLite (FTS5+埋め込みBLOB)
日本語分かち書き Janome 0.5.0
埋め込みモデル multilingual-e5-small (sentence-transformers 6.1.0)
数値計算 numpy 1.26.4
検索方式 BM25+ベクトル → RRF (k=60)
テスト pytest
ホスティング Streamlit Community Cloud
ソース管理 GitHub

凡例

- UI層
- 検索ロジック
- DB層・SQLite
- 開発時/GitHub
- 今回スコープ外 (破線)

→ 矢印: データ・呼び出しの流れ
実線=実装予定あり
破線=今回スコープ外 (次フェーズで実装を検討)

設計の要点

- 単一プロセス (層分離なし)
- 検索時のAPI課金ゼロ (N-02)
- dbはGit管理外。起動時に schema + seeds から自動構築
- 要約は開発時に生成済み。起動時にAPIを呼ばない
- 埋め込みはローカル計算
- search_logs は再起動で消える。デモ中は再起動しない

J-PlatPat (特許公報)
名称・要約・背景・課題・権利状況
を人力で転記
(INPIT開放特許DBは候補探しのみ)

ダミーニーズ/実在FAQ1件
企画系の架空データも含め手動登録
(FAQは出典URLを残す/企画系は画面に「サンプルデータ」と明示)

入力/結果

検索文 (query_side=need)

FTS5検索・ベクトル読込

seeds.sql + schema.sql

デプロイ

カード (①)・一覧/詳細 (②) のデータ取得

タブ① 検索ボタン内でログINSERT (F-04)